Диффузионные методы переноса стиля

Отчёт по первому этапу проекта

Студент: _____ Группа: _____

2026

Введение

В проекте рассматриваются два способа переноса художественного стиля на фотографию: обучение небольшой LoRA-адаптации под выбранный стиль и использование готового IP-Adapter с изображением-образцом. В обоих случаях композиция исходной фотографии задаётся картой контуров Canny через ControlNet. Это позволяет менять способ задания стиля, не меняя структурное условие генерации.

На первом этапе была подготовлена общая схема эксперимента и воспроизведена базовая генерация с IP-Adapter. Для неё собраны изображения, сохранены параметры запуска и рассчитаны показатели сохранения композиции и содержания. Обучение LoRA и прямое сравнение двух методов запланированы на следующий этап. Основной вопрос работы — насколько удаётся передать живописную манеру, не заменив при этом объекты и расположение элементов исходной сцены.

1. Методы переноса стиля

1.1. Базовая модель и структурное условие

В качестве основы используется Stable Diffusion 1.5 — латентная диффузионная модель, генерирующая изображение по текстовому запросу [1]. Денойзинг происходит не в пространстве RGB-пикселей, а в латентном пространстве VAE. На каждом шаге UNet получает зашумлённый латент, номер шага и условия генерации. В исходной модели UNet обучен предсказывать шум, по которому сэмплер рассчитывает следующее состояние латента.

Чтобы изображение не потеряло исходную композицию, в обеих рассматриваемых ветках используется ControlNet Canny [2]. Перед генерацией для фотографии выделяются контуры: сначала изображение переводится в оттенки серого и сглаживается, затем применяется детектор Canny. Карта контуров передаётся в ControlNet и влияет на денойзинг. Контуры задают расположение границ, но сами по себе не содержат сведений о цвете и семантике объектов. Поэтому даже при корректной работе ControlNet предметы могут измениться.

1.2. IP-Adapter и LoRA

IP-Adapter позволяет дополнить текстовый запрос признаками отдельного изображения [3]. Признаки стилевого образца извлекаются визуальным энкодером и поступают в отдельные слои внимания. Вес адаптера управляет влиянием изображения-условия: при слабом весе модель больше опирается на текст, при сильном может активнее заимствовать

цвет, фактуру и объекты образца. Для первого этапа этот метод выбран в качестве baseline, поскольку его веса доступны в готовом виде.

LoRA работает иначе [4]. В ней к некоторым весовым матрицам базовой модели добавляется обучаемая поправка низкого ранга: $W = W_0 + (\alpha/r)BA$, где r — ранг, а B и A — небольшие обучаемые матрицы. При обучении исходные веса Stable Diffusion остаются замороженными. Для каждого исследуемого ранга нужна отдельная тренировка; коэффициент применения LoRA можно менять уже при генерации, без повторного обучения.

Ключевое различие состоит в источнике стиля. IP-Adapter получает конкретную картину при каждом запуске, а LoRA усваивает общие признаки из набора изображений во время обучения. При сравнении методы не объединяются в один пайплайн: запускаются две независимые ветки с одинаковыми исходными фотографиями, текстовыми запросами, ControlNet и начальными шумами.

Вариант	Что задаёт стиль	Что остаётся общим
IP-Adapter	Готовый адаптер и картина-образец	SD 1.5, ControlNet Canny, текст, фото, шум
LoRA	LoRA, обученная на изображениях одного стиля	SD 1.5, ControlNet Canny, текст, фото, шум

Кроме постоянного коэффициента, на втором этапе предполагается проверить изменение силы стилевого условия по шагам генерации. Планируются два линейных расписания: постепенное усиление и постепенное ослабление. Среднее значение веса оставляется тем же, что и у постоянного варианта. Это позволит отделить эффект порядка применения условия от простого увеличения его средней силы.

2. Данные и параметры эксперимента

2.1. Изображения

Для передачи стиля выбран импрессионизм. Из WikiArt (набор huggan/wikiart) отобрано 45 изображений этой категории: 40 предназначены для обучения LoRA и 5 — для отложенной проверки [5]. В baseline используется одна заранее зафиксированная картина из обучающей части. На ней изображена городская улица с пешеходами и экипажем; это важно для интерпретации результатов, поскольку IP-Adapter может переносить элементы такой сцены вместе с её живописной фактурой.



Рисунок 1 — Стилевой образец для IP-Adapter (WikiArt).

В качестве исходных фотографий выбрано 25 изображений из COCO val2017 [6]. Пять отведены под настроечную выборку (dev), двадцать — под тестовую (test). В обеих группах

для каждой фотографии использовались три фиксированных начальных шума: 17, 42 и 123. Получилось 15 результатов для dev и 60 для test.

Фотографии переводились в RGB, обрезались по центральному квадрату и приводились к размеру 512 × 512. Для получения управляющего изображения применялись Gaussian Blur (ядро 5 × 5, σ = 1) и Canny с порогами 100 и 200. Текстовый запрос составлялся из фразы «An impressionist painting» и подписи COCO для конкретной фотографии. Один и тот же запрос будет использоваться при сравнении с LoRA.

2.2. Конфигурация baseline

Параметр	Значение
Базовая модель	stable-diffusion-v1-5/stable-diffusion-v1-5
Условие композиции	lllyasviel/control_v11p_sd15_canny
Стиль	h94/IP-Adapter, ip-adapter_sd15.safetensors
Сэмплер	DDIM, 30 шагов, η = 0
Генерация	512 × 512; CFG = 7,5; batch size = 1
Вес ControlNet / IP-Adapter	0,8 / 0,6, постоянные на всех шагах
Начальные шумы	17, 42, 123; сохранены отдельными тензорами
Вычисления	Google Colab, NVIDIA Tesla T4 (15 ГиБ), fp16, CPU offload

Эксперимент запускался в Google Colab с Python 3.13.16. Модель видеокарты подтверждена выводом nvidia-smi: NVIDIA Tesla T4, объём памяти 15 360 МиБ. Это снимок окружения после эксперимента, а не измерение загрузки GPU в момент генерации. Ревизии весов и полный набор параметров сохранены в models.lock.json и configs/baseline.json.

Для воспроизводимости использовались не только номера seed: начальные тензоры шума сохранялись в файлы и повторно передавались при генерации. Это особенно важно для второго этапа, где различные методы должны начинать работу с одного и того же шума. Тестовые фотографии не планируется использовать для выбора коэффициентов.

3. Оценка качества и протокол

В работе проверяются три разные стороны результата: композиция, содержание и выраженность художественного стиля. Одной метрикой их описать нельзя: изображение может выглядеть живописно, но при этом потерять исходный объект.

3.1. Сохранение композиции

Совпадение контуров измерялось через Edge F1 с допуском на небольшое смещение границ (2 пикселя). Для исходной фотографии и результата строятся карты Canny. Точность P показывает, какая доля контурных точек результата находится не дальше двух пикселей от исходных границ; полнота R — какая доля исходных точек имеет близкую границу в результате. Итоговая оценка: F1 = 2PR/(P + R). Значение приближается к единице при хорошем совпадении контуров, однако может снижаться из-за живописной фактуры и новых деталей.

3.2. Сохранение содержания

Для оценки близости изображений использовалась модель DINOv2-small [7]. Из её выходных признаков извлекался CLS-вектор, нормировался по L2, после чего вычислялось косинусное сходство оригинала и результата. Этот показатель чувствителен к сходству общего визуального содержания, но не гарантирует сохранения всех объектов и деталей сцены. Он также не оценивает стиль напрямую.

3.3. Визуальная оценка и время

Визуальный разбор проводился по исходным фотографиям и сохранённым генерациям. Отмечались узнаваемость основного объекта, изменения фона и заметные живописные признаки. Отдельного исследования с независимыми оценщиками и числовыми баллами соответствия стилю не проводилось. Поэтому в итоговой таблице нет искусственно рассчитанного «балла стиля».

Время учитывалось для генерации одного изображения после прогрева модели; загрузка весов и сохранение PNG в этот замер не входили. Для доверительных интервалов сначала усреднялись три генерации одной фотографии, затем проводился bootstrap по фотографиям (2000 повторов). Такой подход не считает три варианта одного исходника полностью независимыми наблюдениями.

4. Результаты воспроизведения baseline

Для всех 25 фотографий успешно получены три варианта генерации — всего 75 изображений. На каждый результат пришлось по 30 вызовов UNet и ControlNet. Автоматический safety checker не отметил ни одной генерации. Полученные файлы, покадровые метрики и конфигурации включены в архив проекта.

Метрика	Dev (5 фото, 15 генераций)	Test (20 фото, 60 генераций)
Edge F1	0,439 [0,334; 0,522]	0,375 [0,308; 0,433]
DINO cosine	0,393 [0,227; 0,537]	0,329 [0,238; 0,420]
Время, с/изображение	22,40 [21,46; 23,33]	23,64 [23,59; 23,68]

В квадратных скобках указаны 95%-е bootstrap-интервалы. Основным результатом следует считать test: на 20 новых фотографиях среднее Edge F1 составило 0,375, а DINO cosine — 0,329. Это не высокие показатели точного сохранения исходной сцены; в ряде случаев модель сохраняла центральный объект, но заметно перестраивала окружение. Разница между dev и test сама по себе не доказывает переобучения — выборки небольшие и содержат разные сюжеты.

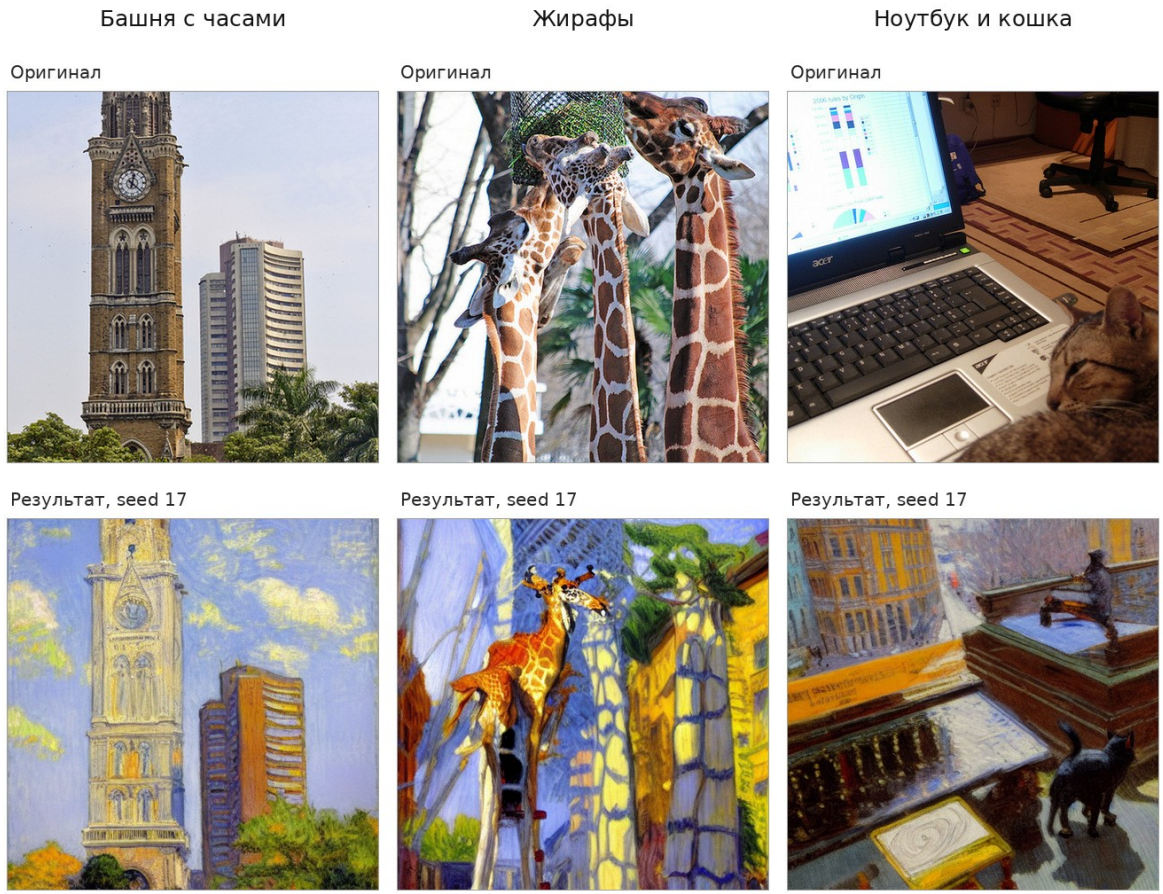


Рисунок 2 — Примеры генерации с IP-Adapter + ControlNet: исходные фотографии и результаты для seed 17. Показаны случаи различной степени сохранения содержания.

На примере башни с часами сохранились силуэт, расположение и крупные элементы сцены. У жирафов основной объект остаётся узнаваемым, но фон превращается в архитектурный пейзаж. В примере с ноутбуком и кошкой происходит существенная замена содержания: исходная обстановка почти не сохраняется. Такие отличия объясняют, почему положительный визуальный эффект стиля не равен успешному переносу исходной фотографии.

Во многих результатах появляются городские здания, улицы и другие детали, похожие по тематике на выбранную стилевую картину. Вероятная причина — IP-Adapter передаёт не только фактуру и палитру, но и содержательные признаки образца. Вывод относится к данному референсу и настройкам, а не ко всем возможным изображениям импрессионизма.

Среднее время генерации на тестовой выборке составило 23,64 с на изображение на Tesla T4. Показатель зафиксирован для указанного режима fp16 и CPU offload; сопоставлять его с измерениями на других GPU без учёта режима загрузки модели некорректно.

5. План экспериментов второго этапа

Следующий этап состоит из обучения двух стилевых LoRA и сравнения их с IP-Adapter при неизменном ControlNet. В качестве обучающих данных используются 40 отобранных картин импрессионизма. Предлагается обучить две независимые LoRA с рангами 4 и 16. Для обеих фиксируются одинаковые 1000 шагов оптимизатора, learning rate 10^{-4}, batch size

1, накопление градиента по четырём батчам, fp16 и gradient checkpointing. Обучаются только LoRA-слои UNet; веса базовой модели, ControlNet и IP-Adapter не обновляются [8]. Эти параметры предварительные и могут потребовать корректировки по доступной памяти и виду промежуточных результатов.

Для настройки коэффициентов используется только dev-набор. Планируются три значения веса IP-Adapter (0,3; 0,6; 0,9), два ранга LoRA с тремя весами применения (0,5; 0,8; 1,1) и по два линейных расписания стилевого коэффициента для каждого метода. Для LoRA расписания сначала проверяются на ранге 4. Дополнительно предусматривается контрольная ветка SD 1.5 + ControlNet без стилевого адаптера. Всего получается 14 конфигураций для предварительной проверки; каждая тестируется на 5 фотографиях и 3 начальных шумах.

Сравнение	**Для чего проводится**
Ранг LoRA: 4 против 16	Оценить влияние числа обучаемых параметров на выраженность стиля и сохранение содержания.
Постоянные коэффициенты	Найти рабочий компромисс между стилем и структурой.
Усиление / ослабление по шагам	Проверить, имеет ли значение момент приложения стилевого условия.
IP-Adapter против LoRA	Сравнить перенос из одной картины и стиль, усвоенный из набора изображений.

При сравнении расписаний их средний вес остаётся одинаковым, меняется лишь распределение по шагам. Гипотеза состоит в том, что слабое стилевое воздействие в начале траектории может помочь сохранить общую композицию, а усиление ближе к концу — передать фактуру. Обратный порядок нужен для проверки этой гипотезы, а не только для демонстрации другого результата.

После выбора нескольких конфигураций на dev планируется повторить их на 20 тестовых фотографиях с теми же тремя начальными шумами, что и у baseline. Сравнение будет проводиться по парным изменениям Edge F1 и DINO, времени генерации и визуальному соответствию стилю. Для последней оценки целесообразно перемешать результаты и проводить просмотр без указания метода. Основные риски следующего этапа — переобучение LoRA на 40 изображениях, заимствование предметов из стилевого референса и ограничение памяти Tesla T4.

Заключение

На первом этапе подготовлены данные и общая схема сравнения двух методов переноса стиля. Baseline с IP-Adapter и ControlNet воспроизведён на Stable Diffusion 1.5: для 25 фотографий COCO получено 75 изображений, рассчитаны Edge F1, DINO cosine и время генерации. На тестовой выборке Edge F1 составил 0,375, DINO cosine — 0,329, среднее время — 23,64 с на изображение. Визуальные примеры показывают, что импрессионистская обработка заметна, однако часть сюжетов сильно меняется. Эти результаты будут служить отправной точкой для обучения LoRA и дальнейшего сравнения способов задания стиля.

Список литературы

[1] Rombach R. et al. High-Resolution Image Synthesis with Latent Diffusion Models. CVPR, 2022. https://arxiv.org/abs/2112.10752

[2] Zhang L., Rao A., Agrawala M. Adding Conditional Control to Text-to-Image Diffusion Models. ICCV, 2023. https://arxiv.org/abs/2302.05543

[3] Ye H. et al. IP-Adapter: Text Compatible Image Prompt Adapter for Text-to-Image Diffusion Models. 2023. https://arxiv.org/abs/2308.06721

[4] Hu E. J. et al. LoRA: Low-Rank Adaptation of Large Language Models. ICLR, 2022. https://arxiv.org/abs/2106.09685

[5] WikiArt: набор huggan/wikiart. https://huggingface.co/datasets/huggan/wikiart

[6] Lin T.-Y. et al. Microsoft COCO: Common Objects in Context. ECCV, 2014. https://arxiv.org/abs/1405.0312

[7] Oquab M. et al. DINOv2: Learning Robust Visual Features without Supervision. 2023. https://arxiv.org/abs/2304.07193

[8] Hugging Face Diffusers: LoRA training. https://huggingface.co/docs/diffusers/en/training/lora

[9] ControlNet v1.1 Canny: model card. https://huggingface.co/lllyasviel/control_v11p_sd15_canny

[10] Hugging Face Diffusers: IP-Adapter. https://huggingface.co/docs/diffusers/en/using-diffusers/ip_adapter